

Unsupervised Pothole Segmentation using K-Means Clustering and Morphological Refinement.

Dian Rakhmawati Lestari¹, Fadhlán Nur Rachman², Matthew Ken Susanto³, Nasauramecca Nour Haqqanshah Shodiqin⁴, Nicholas⁵

^{1,2,3,4,5}*School of Computer Science, Computer Science – Intelligent System*

I. Problem Statement

Lubang jalan adalah bentuk kerusakan infrastruktur yang sering terjadi akibat cuaca ekstrem, beban kendaraan berlebih, dan kurangnya perawatan. Hal ini menimbulkan risiko keselamatan bagi pengguna jalan, seperti kecelakaan, kerusakan kendaraan, hingga kemacetan lalu lintas. Pemantauan kerusakan jalan secara manual saat ini memakan waktu dan tenaga yang besar. Pendekatan *Deep Learning* sering kali terlalu berat untuk perangkat *mobile* atau *edge device*. Selain itu, tantangan teknis seperti variasi pencahayaan dan bayangan yang menyerupai warna lubang sering menyebabkan *false positive*. Proyek ini bertujuan mengembangkan sistem segmentasi otomatis yang ringan dan efisien menggunakan algoritma *unsupervised learning* untuk mengenali area lubang secara presisi.

II. Dataset Source and Description

Dataset yang digunakan berasal dari data kompetisi internal Computer Vision yang mencakup kondisi jalanan di Indonesia [Dataset ARA 7.0](#):

1. Training Set (Images & Masks)
Berisi 498 gambar jalanan beserta *mask ground truth* yang menandai area lubang secara piksel. Data ini akan digunakan untuk mencari nilai optimal centroid pada *K-Means*.
2. Test Set
Berisi 295 gambar tanpa *mask* untuk menguji kemampuan generalisasi model pada data baru.
3. Data Karakteristik
Citra mencakup variasi sudut pengambilan gambar (*high-angle*), tekstur aspal yang beragam (halus/kasar), dan gangguan visual seperti bayangan pohon atau pantulan air.

III. Initial Plan Model/Methodology

Kami akan membandingkan dua pendekatan tradisional untuk melihat efektivitasnya:

1. Baseline Model (Adaptive Tresholding)

Sebagai model pembanding, penelitian ini menggunakan metode Adaptive Tresholding untuk melakukan segmentasi lubang pada jalan. Metode ini dipilih karena lebih sederhana, ringan dalam komputasi, serta mampu menangani variasi pada pencahayaan. Alih-alih hanya menggunakan satu nilai treshold untuk seluruh gambar seperti tresholding global, metode Adaptive Tresholding menghitung nilai treshold secara lokal berdasarkan intensitas piksel disekitar area. Hal ini membuat metode ini lebih robust terhadap kondisi pencahayaan yang tidak merata pada citra jalan.

2. Advanced Model (K-Means Clustering & Morphological Refinement)

Model utama yang mengelompokkan piksel berdasarkan fitur warna dan tekstur:

- Preprocessing: Konversi ke ruang warna *Lightness* atau *Saturation* untuk mengambil karakteristik tekstur. Atau pun menggunakan *Grayscale* dan aplikasi CLAHE untuk meningkatkan kontras atau tekstur visual area lubang dibawah bayangan.
- Clustering: Menerapkan *K-Means* dengan $K = 3$ hingga 5 untuk memisahkan komponen citra menjadi: (1) Aspal normal, (2) Area gelap/lubang, dan (3) Marka jalan/*noise*.
- Post-processing: Menggunakan operasi morfologi (*Closing*) untuk menyatukan area lubang yang terpecah dan *Contour Filtering* menghapus objek-objek kecil yang bukan merupakan lubang jalan.



IV. Evaluation Metrics and Success Criteria

Untuk mengukur keakuratan segmentasi pada tingkat piksel, model akan dievaluasi menggunakan:

1. Mean Intersection over Union (mIoU):

Mengukur rasio tumpang tindih antara hasil prediksi model dengan *ground truth*. Ini adalah metrik paling kritikal untuk tugas segmentasi.

$$IoU = \frac{|Area_Prediksi \cap Area_Asli|}{|Area_Prediksi \cup Area_Asli|}$$

2. Dice Coefficient (F1-Score):

Mengukur tingkat kemiripan antara hasil prediksi dan data asli untuk mengevaluasi seberapa banyak piksel lubang yang terdeteksi dengan benar.

$$\text{Dice} = \frac{2TP}{2TP + FP + FN}$$

3. Pixel Accuracy:

Menghitung persentase piksel yang diklasifikasikan dengan benar ke dalam kategori lubang atau non-lubang

Success Criteria

Model yang dikembangkan mampu mendeteksi lubang jalan dengan tepat, stabil dan konsisten dalam berbagai kondisi lingkungan yang berbeda secara otomatis dengan nilai mIoU > 0,6. Hal ini seperti pencahayaan yang berbeda, seperti kondisi terang dan redup, sudut pengambilan gambar dan kualitas gambar. Dengan kemampuan tersebut, model ini mampu membantu proses identifikasi kerusakan jalan secara lebih efisien dibandingkan pemantauan manual yang bergantung pada observasi manusia.

V. References

- Nienaber, S., Booysen, M. J., & Kroon, R. S. (2015). Detecting Potholes using Simple Image Processing Techniques and Real-World Footage. Proceedings of the 34th Southern African Transport Conference. [\(PDF\) Detecting Potholes Using Simple Image Processing Techniques and Real-World Footage](#)
- Otsu, N. (1979). A Threshold Selection Method from Gray-Level Histograms. IEEE Transactions on Systems, Man, and Cybernetics, 9(1), 62-66. [A Threshold Selection Method from Gray-Level Histograms | IEEE Journals & Magazine | IEEE Xplore](#)
- Safyari, Y., Mahdianpari, M., et al. (2022). A Review of Vision-Based Pothole Detection Methods Using Computer Vision and Machine Learning. [A Review of Vision-Based Pothole Detection Methods Using Computer Vision and Machine Learning](#)